CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

SEMANA 4 · BENCHMARKS E COMPORTAMENTO AGÊNTICO

Fundamentos de avaliação de modelos

PERGUNTA ORIENTADORA

O que precisa ser definido para que “o modelo A é melhor que o B” tenha significado científico?

A cadeia de uma avaliação

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

1

Capacidade

O que se quer saber se o modelo faz

NO EXEMPLO

Sentimento além das palavras

2

Tarefa

Como se verifica isso

NO EXEMPLO

Classificar em 3 classes

3

Dataset

Coleção de exemplos que instancia a tarefa

NO EXEMPLO

55 frases rotuladas

4

Exemplo

Uma unidade de teste

NO EXEMPLO

Uma frase do dataset

5

Resposta esperada

O gabarito de cada exemplo

NO EXEMPLO

O rótulo correto da frase

A métrica vem depois: ela compara a resposta do modelo com a resposta esperada.

Capacidade e tarefa

CAPACIDADE

A competência que se quer verificar no modelo

Existe mesmo que ninguém a teste. É um conceito abstrato, não observável diretamente.
“**Construto**”.

Ex.: entender sentimento além das palavras

medida por

TAREFA

Um exercício com entrada e saída definidas

É o **proxy** observável da capacidade: a forma específica de testá-la.

Ex.: classificar frases em 3 classes

Mesma capacidade, tarefas diferentes:

- 3 classes
- Nota de 1 a 5
- Justificar o rótulo

Dataset, exemplo e resposta esperada

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

3

Dataset

A coleção de exemplos que instancia a tarefa.

N exemplos = 1 dataset

4

Exemplo

Entrada + Golden = Exemplo

5

Resposta esperada

O gabarito (gold) que o modelo deveria produzir. Parte do exemplo, que, por sua vez, é parte do dataset.

UM EXEMPLO DO DATASET

ENTRADA

Amei esperar 40 minutos pelo ônibus debaixo de chuva.

RESPOSTA ESPERADA

Negativo

Exemplo do script (55 frases). Benchmarks reais, como o GSM8K, têm milhares.

Acertar a tarefa prova a capacidade?

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

VALIDADE DE CONSTRUTO

A tarefa é um proxy da capacidade, nunca a capacidade em si.

Acertar o benchmark só implica ter a capacidade se o proxy for fiel.

Exemplo clássico: aprender o atalho

1

Raios-x de hospitais diferentes

Hospitais com casos mais graves usam aparelhos e marcações próprios.

2

O modelo encontra uma pista

Reconhece o hospital de origem, que se correlaciona com a doença.

3

Acerta pela razão errada

Vai bem no teste, mas falha em dados de outro hospital.

Ex.: Zech et al., 2018 (detecção de pneumonia em raios-x)

Três perguntas antes de confiar num benchmark

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

1

Validade de construto

A tarefa mede mesmo a capacidade ou uma pista?

Se falhar: o modelo acerta por atalho, não por capacidade.

2

Validade de conteúdo

O dataset cobre toda a variação da capacidade ou só os casos fáceis?

Se falhar: capacidade mais estreita do que parece (script: 17 de 33 simples).

3

Demonstrada ≠ real

O resultado ruim é falta de capacidade ou falha do teste?

Se falhar: prompt, formato ou dados ruins escondem o que o modelo sabe.

Treino, validação e teste

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

1 Treino

Ajusta os pesos

Atualizar gradiente, loss, w e bias. Usado no treinamento do modelo.

2 Validação

Ajusta as decisões

Não mexe nos pesos. No script: 22 frases, onde se escolhe zero-shot ou few-shot.

3 Teste

Só mede, uma vez

Fora de todo treino e decisão. No script: 33 frases, usadas uma única vez.

O USO DEFINE O SPLIT, NÃO O NOME

Se os 20% reservados serviram para parar o treino (early stopping), eram validação, mesmo rotulados “teste”. O benchmark externo, olhado só no final, era o teste.

O que se decide na validação

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

A REGRA

Toda decisão que olha um resultado entra na validação.

Rodar a validação é só inferência: o modelo não muda. Quem muda é a decisão de quem desenvolve.

NO TREINO	NA AVALIAÇÃO DE LLM
Taxa de aprendizado e épocas	O prompt: zero-shot ou few-shot (hiperparâmetro)
Quando parar (early stopping)	Quantos exemplos few-shot (no script, 4)
Qual checkpoint usar	Temperatura
Arquitetura ou tamanho do modelo	Parser da resposta (script: regex)

Baseline de Modelos

“Meu modelo tem 85% de acurácia.”
Afinal, isso é bom?

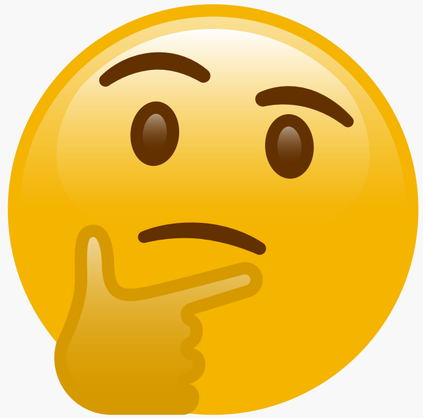

Um número sozinho não diz nada

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

TAREFA 1: TRÊS CLASSES BALANCEADAS

85% acurácia do modelo

Baseline aleatório	33%

Bem acima do acaso

TAREFA 2: 95% DOS EXEMPLOS NA MESMA CLASSE

85% acurácia do modelo

Sempre a classe majoritária	95%

Pior que ignorar a entrada

Baseline é a referência que dá significado ao número: o mesmo 85% é bom numa tarefa e fraco na outra.

O que é um baseline?

Baseline: a referência simples contra a qual eu comparo o modelo. Ela responde: melhor que o quê?

Em benchmark, o score vem com referências

Piso — o acaso ou a classe majoritária.
Regra simples — palavras-chave, um modelo clássico.
Humano — o que uma pessoa alcança na mesma tarefa.
Outros modelos — os demais do leaderboard.

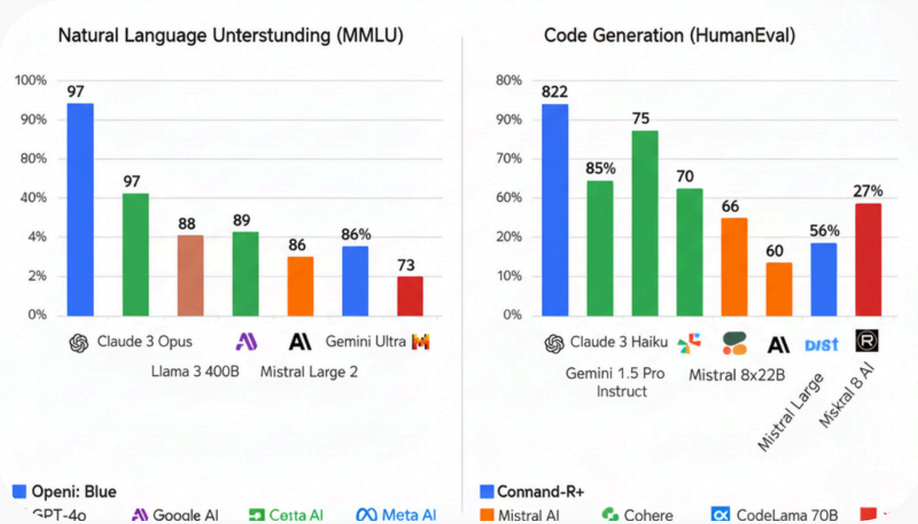

O score nunca vem sozinho. Os modelos passam de todos os baselines, então são bons. Mas qual é melhor?

Comparação controlada

CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

A REGRA

Só uma variável muda: o modelo.

Se duas coisas mudam, não dá para saber a qual atribuir a diferença.

Dataset e split

Os mesmos exemplos de teste

Prompt e few-shot

Mesmo template e mesmos exemplos

Decodificação

Temperatura, top-p e limite de tokens

Nº de tentativas

pass@1 não compara com pass@5

Parser

A mesma extração e o mesmo cálculo

Harness

O mesmo código avalia os dois

Concluindo...

Se os benchmarks não seguem um padrão na avaliação, não dá para definir o modelo mais viável. É necessário uma comparação *justa*.

Justo não é o mesmo que real

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

A 100% e B 97%, com 33 exemplos de teste

Modelo A: 100% (33/33)

Modelo B: 97% (32/33)

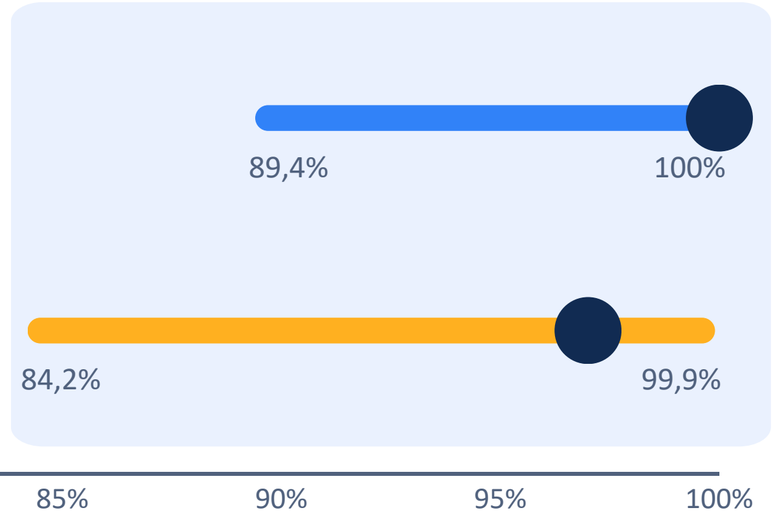

Faixa em que o desempenho real provavelmente está (IC 95% exato)

QUANTO RUÍDO?

$$EP = \sqrt{(p \cdot (1 - p) / n)}$$

$$IC\ 95\% = p \pm 1{,}96 \cdot EP$$

n (com p ≈ 84%)	Meia-largura do IC
100	± 7,2 pontos
400	± 3,6 pontos
1.000	± 2,3 pontos
5.000	± 1,0 ponto

Padronizar garante uma comparação justa. Só um IC ou um teste pareado (McNemar) mostra se a diferença supera o ruído: aqui, 1 exemplo separa A de B (p = 1,0). Perto de 100%, a fórmula do EP dá zero; use o IC exato.

Respondendo à pergunta orientadora

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

O que precisa ser definido para que “o modelo A é melhor que o B” tenha significado científico?

1

O que medir

Capacidade, tarefa, dataset, exemplo e resposta esperada, com validade de construto e de conteúdo.

2

Sem se enganar

Treino, validação e teste, com decisões só na validação e o teste olhado uma vez.

3

Contra o quê

Um baseline que dê sentido ao número, avaliado no mesmo teste e protocolo.

4

A diferença é real?

Só o modelo muda, e a diferença precisa superar o ruído da amostra.

A seguir: métricas, avaliação humana e por LLM, benchmark, harness, leaderboard e contaminação.

A matriz de confusão

Exemplo: detector de spam avaliado em 1.000 e-mails, dos quais 50 são spam. O modelo marca 40 como spam, e 30 desses são realmente spam.

	Realmente spam	Realmente não spam
Modelo disse spam	VP = 30	FP = 10
Modelo disse não spam	FN = 20	VN = 940

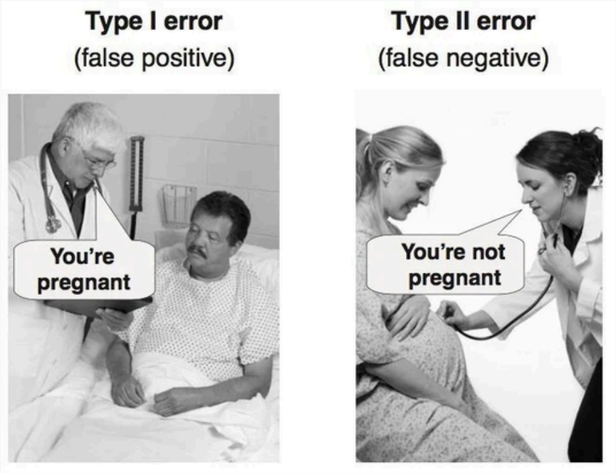

Métrica	Fórmula	Pergunta que responde	Valor no exemplo
Acurácia	(VP + VN) / total	De tudo, quanto acertou?	970 / 1.000 = **97%**
Precisão	VP / (VP + FP)	Quando diz "spam", quanto acerta?	30 / 40 = **75%**
Recall	VP / (VP + FN)	Dos spams que existem, quantos encontrou?	30 / 50 = **60%**
F1	2 · P · R / (P + R)	Equilíbrio entre precisão e recall (média harmônica)	2 · 0,75 · 0,60 / 1,35 = **66,7%**

A matriz de confusão

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

BASELINE PALAVRAS-CHAVE · TESTE, n = 33

VERDADEIRO ↓ \ PREDITO →	Positivo	Negativo	Neutro
Positivo	6	0	4
Negativo	3	5	4
Neutro	1	1	9

Azul: acertos (diagonal). Amarelo: frases que viraram Neutro sem ser.

1 **Diagonal = acertos**

6 + 5 + 9 = 20 de 33 frases: acurácia de 61%.

2 **Linha = o que a frase era**

Dos 12 negativos, só 5 foram reconhecidos.

3 **Coluna = o que o sistema disse**

17 frases viraram Neutro, e 8 delas não eram.

Toda métrica de classificação sai desta tabela. No modelo B, a matriz tem um único erro fora da diagonal: um Negativo lido como Neutro.

Quatro métricas, quatro perguntas

Classe Negativo, palavras-chave: **VP = 5** acertos **FP = 1** alarme falso **FN = 7** negativos que passaram

	Previu negativo	Previu outra classe
Era negativo	VP = 5 Acertou	FN = 7 Deixou passar
Era outra classe	FP = 1 Alarme falso	VN = 20 Rejeitou certo

ACURÁCIA TOTAL

acertos / total

De tudo, quanto acertou?

61%

20 / 33, todas as classes

PRECISÃO

$$\frac{VP}{(VP + FP)}$$

Quando diz Negativo, acerta?

83%

5 / (5 + 1)

RECALL

$$\frac{VP}{(VP + FN)}$$

Dos negativos, quantos achou?

42%

5 / (5 + 7)

F1

$$\frac{2 \cdot P \cdot R}{(P + R)}$$

Equilíbrio entre P e R

56%

média harmônica

Mesmo sistema, quatro números. 83% de precisão com 42% de recall descrevem um classificador cauteloso: só diz Negativo diante de palavra explícita.

Três classes: uma rodada por classe

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

RODADA 1 · POSITIVO É O "SPAM"

	disse Positivo	disse outra
era Positivo	VP 6	FN 4
era outra	FP 4	VN 19

Precisão	Recall	F1
60%	60%	60%
6 / 10	*6 / 10*	

RODADA 2 · NEGATIVO É O "SPAM"

	disse Negativo	disse outra
era Negativo	VP 5	FN 7
era outra	FP 1	VN 20

Precisão	Recall	F1
83%	42%	56%
5 / 6	*5 / 12*	

RODADA 3 · NEUTRO É O "SPAM"

	disse Neutro	disse outra
era Neutro	VP 9	FN 2
era outra	FP 8	VN 14

Precisão	Recall	F1
53%	82%	64%
9 / 17	*9 / 11*	

Média macro: soma as três rodadas e divide por 3. Cada classe pesa igual.

PRECISÃO MACRO

(60 + 83 + 53) / 3

= 65%

RECALL MACRO

(60 + 42 + 82) / 3

= 61%

F1 MACRO

(60 + 56 + 64) / 3

= 60%

E a acurácia?

Não precisa de rodadas: soma a diagonal da matriz 3×3.

(6 + 5 + 9) / 33 = 61%

Precisão ou recall: qual erro custa mais?

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

NEGATIVO

83%
precisão

42%
recall

Quando diz Negativo, quase sempre acerta. Mas deixa passar 7 de 12: sarcasmo e negação não têm palavra negativa.

Priorize recall quando deixar passar é caro

Triagem médica, fraude, discurso de ódio.

NEUTRO

53%
precisão

82%
recall

Sem palavra-chave, tudo vira Neutro: acha 9 de 11 neutros, mas 8 das 17 frases que chamou de Neutro não eram.

Priorize precisão quando o alarme falso é caro

Bloquear e-mail legítimo, acusar alguém de fraude.

O F1 junta os dois e cai quando um deles é baixo: 56% no Negativo e 64% no Neutro. Em geral, ajustar o sistema para subir um derruba o outro.

Acurácia ou F1 macro?

CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

Acurácia e F1 macro no teste (n = 33)

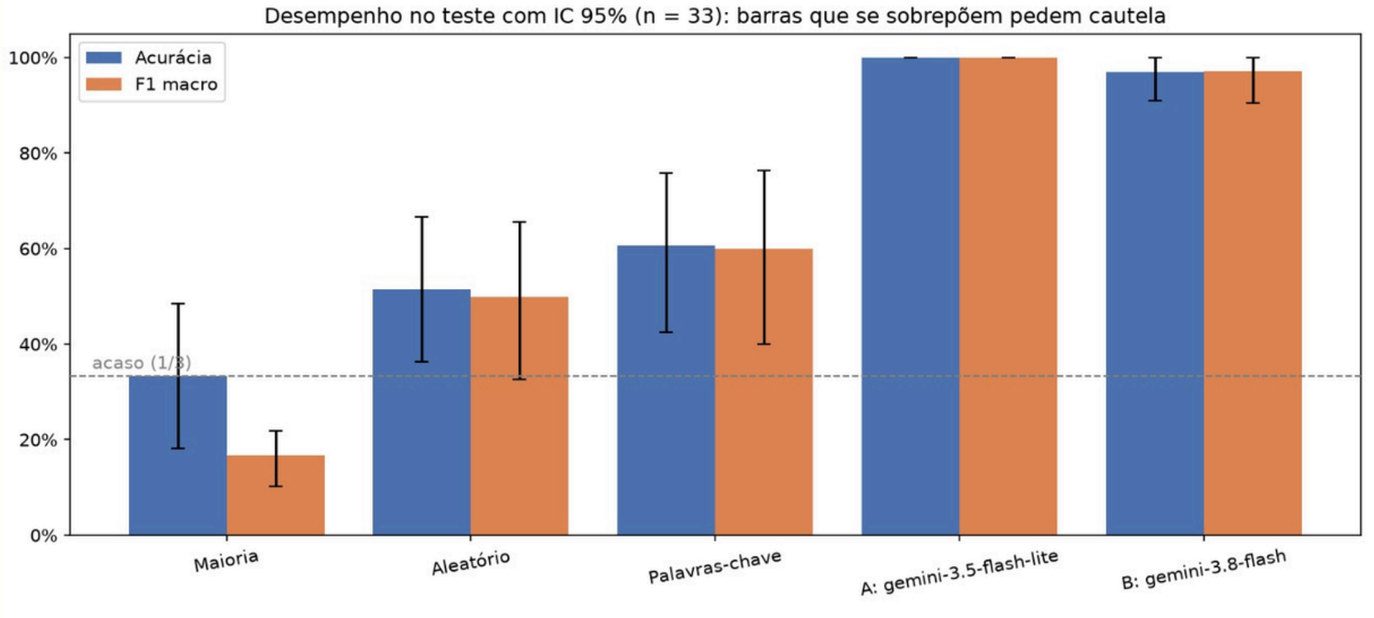

1 **Média simples por classe**

Calcula o F1 de cada classe e tira a média: cada classe pesa igual.

2 **Maioria: 33% vs 17%**

A acurácia parece de acaso; o F1 macro mostra que duas classes foram ignoradas.

3 **Desbalanceio aumenta a distância**

Aqui o teste é quase balanceado (10/12/11). Com 95% de uma classe, a acurácia engana.

Exact match: conteúdo e formato

CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

A REGRA

Vale 1 só se a saída, normalizada, for idêntica ao gabarito.

Normalizar: minúsculas, sem pontuação e sem espaços extras.

Texto livre: F1 por tokens dá crédito parcial. “29 lápis” contra “29”: EM 0, F1 0,67.

SAÍDA DO MODELO	EM	APÓS A EXTRAÇÃO
Negativo	1	**Negativo**
O sentimento é Negativo.	0	**Negativo**
Depende do contexto.	0	**Inválido**
Positivo ou Negativo?	0	**Inválido**

NO SCRIPT

A e B responderam 100% no formato, sem inválidas. Uma regra de extração mais frouxa ou mais rígida mudaria a nota: ela precisa ser a mesma para todos.

Quem decide se a resposta está certa?

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

1 Automática

Por regra

Compara com o gabarito ou executa um verificador.

BOM PARA

Classificação, matemática, código com testes.

Barata e reproduzível

Risco: Penaliza resposta certa em outro formato; BLEU e ROUGE medem palavras em comum, não qualidade.

2 Por LLM

LLM como juiz

Um modelo recebe a resposta e uma rubrica e dá nota ou escolhe a melhor.

BOM PARA

Texto aberto em escala (MT-Bench, AlpacaEval).

Rápida perto da humana

Risco: Vieses do juiz; precisa ser validado contra humanos.

3 Humana

Pessoas

Avaliadores dão nota ou comparam duas respostas.

BOM PARA

Utilidade, nuance, segurança (Chatbot Arena).

Cara e lenta

Risco: Discordância entre avaliadores, cansaço, viés pessoal.

Quando o gabarito é discutível

UM EXEMPLO DO TESTE

“O professor mudou a data da prova de novo.”

Gabarito	**Negativo**
Modelo A	**Negativo**
Modelo B	**Neutro**

Erro do modelo ou do gabarito?

AVALIAÇÃO HUMANA BEM FEITA

Rubrica escrita

Critérios claros e exemplos de cada rótulo ou nota.

Avaliação cega

O avaliador não sabe qual modelo gerou a resposta.

Ordem aleatória

As respostas comparadas aparecem em ordem sorteada.

Mais de um avaliador

E uma medida de concordância entre eles, como o kappa de Cohen.

O QUE MAIS PASSA BATIDO

Se os próprios humanos discordam muito, a tarefa está mal definida, e nenhum modelo pode ser julgado com precisão nela.

LLM como juiz: escala com vieses

ZHENG ET AL., 2023 (MT-BENCH)

>80%

de concordância entre o GPT-4 como juiz e humanos, nível parecido ao de humanos entre si.

Bom o bastante para escalar, desde que os vieses sejam controlados.

1 Posição

Prefere a primeira (ou a segunda) resposta mostrada.

Mitigação: Avaliar nas duas ordens.

2 Verbosidade

Prefere respostas longas, mesmo sem mais conteúdo.

Mitigação: Rubrica que penaliza enchimento.

3 Autopreferência

Favorece respostas do próprio modelo ou da mesma família.

Mitigação: Juiz de outra família de modelos.

4 Limite de capacidade

Não julga bem o que não sabe resolver, como matemática difícil.

Mitigação: Fornecer a resposta de referência.

Como escolher a métrica e o juiz

CEIA
CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

Qual métrica?

Sempre	**Olhar a matriz de confusão**
Classes desbalanceadas	**F1 macro, não só acurácia**
Um erro custa mais	**Precisão ou recall**
Saída em texto	**Exact match com extração fixa**

Quem julga?

Gabarito único	**Regra automática**
Texto aberto em escala	**LLM juiz + amostra humana**
Subjetivo ou alto risco	**Humanos com rubrica**
Gabarito duvidoso	**Medir concordância humana**

“A é melhor que B” depende da métrica e de quem julgou.

O que é um Benchmark?

Um benchmark representa aquilo que se mede. É um conjunto padronizado composto por dataset, métrica e protocolo.

O seu principal objetivo é garantir que diferentes modelos sejam comparados exatamente da mesma forma.

Exemplos incluem o **MMLU**, que avalia conhecimento em múltipla escolha, e o **GSM8K**, focado em raciocínio matemático.

Existem também os **benchmarks agênticos**, como o **SWE-bench**, que avalia como um agente resolve problemas (issues) reais em repositórios.

Em resumo: benchmark é o espelho padronizado que mostra o quanto cada modelo realmente entende, raciocina e age bem, sob as mesmas condições.

Harness: A Execução da Avaliação

O **harness** define a forma como a medição do modelo é executada. Trata-se do software que realiza a avaliação de ponta a ponta.

As suas funções incluem carregar exemplos, montar o prompt, chamar o modelo, extrair a resposta, calcular a métrica e guardar os logs.

Detalhes do **harness**, como o template do prompt ou a regra de extração, podem alterar significativamente o resultado final.

Em avaliações agênticas, o **harness** também engloba o **'scaffold'**, que define as ferramentas disponíveis, o ambiente e os limites de passos e tempo.

Leaderboard:
O Ranking Público

CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

O **leaderboard** é o local onde os resultados das avaliações são comparados de forma pública. Apresenta um ranking dos modelos com base nos resultados obtidos num ou mais benchmarks.

O mesmo benchmark, quando executado em harnesses distintos, pode gerar números de ranking diferentes.

Estes rankings sofrem influência da **Lei de Goodhart**, o que significa que otimizar o modelo apenas para subir no ranking pode inflar os números sem melhorar a capacidade real.

Os benchmarks acabam por saturar e perdem a capacidade de separar os modelos quando os melhores atingem um desempenho superior a cerca de **90%.**

Limitações nas Avaliações

Validade de construto: os benchmarks medem o desempenho numa tarefa específica, o que não reflete necessariamente uma capacidade ampla.

Validade externa: um bom desempenho no benchmark nem sempre se traduz em sucesso no uso real do dia a dia.

Erros de referência: datasets de grande escala podem conter respostas no gabarito que estão erradas ou ambíguas.

Sensibilidade ao prompt: pequenas mudanças no formato da entrada podem alterar drasticamente o resultado obtido.

Não determinismo: execuções com temperatura superior a zero, ou agentes com múltiplos passos, resultam em saídas diferentes a cada execução.

Vieses em Modelos e Avaliações

Viés de idioma e cultura: a maioria dos benchmarks reflete a cultura e o contexto norte-americano em língua inglesa. A simples tradução de um teste para português não cria um benchmark adaptado à realidade local.

Viés de seleção de dados: a definição do que é considerado ‘normal’ provém de quem escolheu os exemplos e da origem desses mesmos dados.

Viés do avaliador: tanto os avaliadores humanos quanto os LLMs utilizados como juízes possuem as suas próprias preferências.

Viés social: um modelo pode apresentar uma precisão elevada e, ainda assim, reproduzir estereótipos sociais nas suas respostas.

Contaminação de Dados em LLMs

A **contaminação** acontece quando os exemplos do teste, ou as suas respostas, aparecem nos dados usados para o treino do modelo. Isto permite que o modelo acerte as questões por pura **memorização**, medindo memória em vez de uma real capacidade de raciocínio.

Um **sinal de alerta** ocorre quando o desempenho do modelo cai em versões novas e equivalentes do mesmo teste.

Outro indício é quando o modelo consegue completar perfeitamente o enunciado recebendo apenas o começo de uma pergunta do benchmark.

A **mitigação** deste risco inclui o uso de conjuntos de teste privados e a avaliação com exemplos criados após a data de corte do modelo.