

SEMANA 2

Equipe: Benchmarks e comportamento agêntico

# Como um LLM gera respostas e segue instruções

Reunião de alinhamento de conteúdo — Desvendando o motor probabilístico dos modelos de linguagem.



Pergunta central: Por que o mesmo modelo gera respostas diferentes e o que significa seguir uma instrução?

# Roteiro de Alinhamento

Os tópicos essenciais para desmistificar a geração de texto e o comportamento de agentes.

**01**

## **Arquitetura & Atenção**

Queries, Keys, Values e a Máscara Causal em nível intuitivo.

**02**

## **Geração & Decoding**

Loop autoregressivo, temperatura, top-k, top-p e greedy decoding.

**03**

## **Instruções & Avaliação**

Prompts, chat templates, fluência, correção e resposta final.

# O que um LLM está de fato fazendo?

A ilusão de compreensão humana versus a realidade matemática.

## Missão fundamental

- O modelo não pensa como um humano: ele calcula probabilidades sobre o vocabulário inteiro.
- Cada saída é a escolha estatística do próximo token, com base em todo o contexto anterior.
- Os pesos são ajustados via gradiente, bilhões de vezes, para minimizar o erro de previsão.

$$P(x_i \mid x_1 \dots x_{i-1})$$

Prever a distribuição de probabilidade do próximo token.

# Atenção Causal: Queries, Keys e Values

Três vetores que cada token gera, multiplicando seu embedding por matrizes de peso aprendidas.

**Q**

## Query (Consulta)

O que o token atual procura no texto.

**K**

## Key (Chave)

O rótulo: sob quais condições aquele vetor é relevante.

**V**

## Value (Valor)

O conteúdo informacional que é de fato transferido.

Exemplo: na frase "**saquei dinheiro no banco**", o token "banco" recebe o mesmo embedding inicial, independente do contexto — banco financeiro, banco de sentar ou banco de dados. É a atenção que vai diferenciar isso.

# A Dinâmica de Interação Q, K, V

Calculando a relevância contextual entre tokens.

## O Processo de Cálculo

1. O token gera uma Query, multiplicando seu embedding pela matriz  $W_Q$ , comum a todos os tokens.
2. O modelo compara essa Query contra a Key de cada outro token, via produto escalar.
3. Quanto maior o produto escalar, maior a relação entre os dois tokens.

$$\text{score} = Q \cdot K$$

Uma grade de relação entre a Query de um token e a Key de todos os outros.

$$\text{Attention}(Q, K, V) = \text{softmax} \left( \frac{QK^T}{\sqrt{d_k}} \right) V$$

# Máscara Causal e Contexto Disponível

Por que cada token só pode olhar para o passado.

## O Princípio da Cegueira Futura

- Zera matematicamente a relação de um token com qualquer palavra à sua direita, antes do softmax.
- Impede que o modelo "cole" a resposta durante o treino, em vez de aprender a prever de verdade.
- Permite treinar em paralelo todas as posições da frase, de uma vez só.



Matriz triangular: atenção restrita apenas às posições passadas.

# Geração Autoregressiva: Token por Token

Como o texto é construído: prevendo, colando e repetindo.

## PASSO 01

### Entrada de Contexto

Todo o texto disponível até ali é processado, usando o mecanismo de atenção.

## PASSO 02

### Predição & Decoding

O modelo obtém a distribuição de probabilidade e escolhe o próximo token.

## PASSO 03

### Realimentação (Loop)

O token gerado entra no contexto, e o ciclo recomeça para o próximo.

# Eficiência na Geração: O KV-Cache

Por que o modelo não recalcula todo o histórico a cada novo token.

## O Desafio Computacional

Sem otimização, cada novo token exigiria reprocessar todo o histórico anterior do zero.

## A Solução

Como a máscara garante que Key e Value já calculados nunca mudam, o modelo os guarda em memória e só processa o que é novo.

Até aqui, tudo é determinístico: mesmo input, mesmos pesos, sempre a mesma distribuição de probabilidade. A variabilidade não está em **como** o modelo calcula — está em **como** ele escolhe a partir dela. É isso que vem a seguir, com as estratégias de decoding.

# Estratégias de Decoding: Por que Escolher?

O trade-off fundamental entre previsibilidade determinística e diversidade criativa.

## Sempre o Mais Provável

- Gera respostas altamente previsíveis e consistentes.
- Risco de loops repetitivos e falta de naturalidade ("seguro demais").


## Amostragem Estocástica

- Introduz variação controlada para maior fluência e criatividade.
- Risco de desvio de assunto ou alucinação se mal calibrado.

# Greedy Decoding

A abordagem determinística de escolha estrita por maior probabilidade.

- Em cada passo, escolhe unicamente o token com o maior escore de probabilidade.
- Totalmente determinístico: mesmas entradas geram exatamente a mesma saída.
- Ideal para tarefas objetivas, extração de dados e benchmarks estruturados.



# Temperatura

Reescalando os logits antes da aplicação do softmax.

$$P_i = \frac{e^{z_i}}{\sum_j e^{z_j}} \longrightarrow P_i = \frac{e^{\frac{z_i}{T}}}{\sum_j e^{\frac{z_j}{T}}}$$

**T = 1.0**

## Distribuição Original

Mantém o equilíbrio natural aprendido no treinamento do modelo.

**T > 1.0**


## Alta Aleatoriedade

Achata a distribuição, aumentando a diversidade e o risco de incoerência.

**T → 0**

## Quase Determinístico

Aproxima-se do comportamento greedy, concentrando em tokens prováveis.




# Top-K e Top-P

Filtrando a cauda longa de tokens improváveis para garantir qualidade.


## Top-K (Limite Fixo)

- Mantém apenas os  $k$  tokens mais prováveis em cada passo.
- Simples, mas rígido: não se adapta quando a incerteza do modelo varia.



## Top-P (Adaptativo)

- Soma tokens em ordem decrescente até atingir a probabilidade acumulada  $p$  (ex.: 0.8).
- Dinâmico: expande ou contrai o vocabulário elegível conforme o contexto.



# Loop de repetição

“A IA é incrível, incrível, incrível...”

- **Temperaturas muito baixas** (por exemplo, 0) tornam o modelo excessivamente determinístico e propenso a ficar travado.
- **Temperaturas muito altas** (ex.: 1,0) introduzem aleatoriedade excessiva, causando repetições erráticas.
- **Instruções pouco claras**, que confundem o modelo e levam a respostas automáticas repetitivas.

Bom ponto de partida para resultados equilibrados:

- Temperatura: 0,2
- Top-P: 0,95
- Top-K: 30

**Penalização de repetição:** desencoraja o modelo a utilizar tokens gerados previamente, forçando a seleção de novas palavras

- **Higher values (1.5–2.0):**  
Reduce repetition but can make phrasing less natural.
- **Typical value: 1.2**

| Goal                                  | Parameter                      | Direction                           |
|---------------------------------------|--------------------------------|-------------------------------------|
| More Creative, Diverse Output         | Temperature ↑                  | Encourages less probable words      |
|                                       | Top-P ↑ (0.9–0.95)             | Broadens the sampling pool          |
|                                       | Top-K ↑ (100+)                 | Increases variety                   |
| More Consistent, Deterministic Output | Temperature ↓                  | Makes predictions stable            |
|                                       | Top-P ↓ (0.3–0.5)              | Narrows the candidate pool          |
|                                       | Top-K ↓ (10–20)                | Restricts to highly probable tokens |
| Reduce Repetition                     | Repetition Penalty ↑ (1.2–2.0) | Suppresses repeated tokens          |

# Prompt, System Message e Chat Template

A estrutura de controle que direciona o comportamento conversacional do agente.

## System Message


Instruções persistentes de papel, tom, restrições e diretrizes globais.

## Prompt do Usuário

A pergunta ou tarefa pontual enviada na iteração da vez.

## Chat Template

Marcadores especiais que estruturam quem fala com quem no modelo.



- Instrução - uma tarefa ou instrução específica que você deseja que o modelo execute
- Contexto - pode envolver informações externas ou contexto adicional que pode direcionar o modelo para melhores respostas
- Dados de entrada - é a entrada ou pergunta para a qual estamos interessados em encontrar uma resposta
- Indicador de saída - indica o tipo ou formato da saída.

```
<|im_start|>system
You are a helpful assistant.<|im_end|>
<|im_start|>user
Hello!<|im_end|>
<|im_start|>assistant
Hi! How can I help you today?<|im_end|>
<|im_start|>user
What's the weather?<|im_start|>assistant
```

# Chat Template: Por que é Crítico?

O impacto de formatar corretamente tokens especiais de sistema.

```
<im_start>system
```

```
Você é um assistente útil.
```

```
<im_end>
```

```
<im_start>user
```

```
Resuma a teoria da relatividade.
```

```
<im_end>
```

```
<im_start>assistant
```

## Consequências do Erro

- Sem o template adequado, o modelo perde a noção de papéis.
- Entra em modo de "completar texto genérico" em vez de responder como assistente.
- Cada família de modelo (Llama, Mistral, Gemma) exige seu próprio padrão exato.

# Fluência x Correção x Cumprimento

Três dimensões independentes de qualidade que precisam ser medidas separadamente.

## Fluência

O texto soa natural, gramaticalmente correto e coerente?

## Correção

A informação apresentada é factualmente verdadeira e precisa?

## Cumprimento

A resposta atendeu rigorosamente ao formato e restrições da instrução?

# Por que o mesmo modelo gera respostas diferentes?

Fontes de variação estocástica e numérica na inferência de LLMs.

- **Decoding Estocástico:**

Amostragem com temperatura  $> 0$ , top-k e top-p introduz variação intencional.

- **Não-determinismo de**

**Hardware:** Kernels de GPU paralelos e arredondamentos numéricos em ponto flutuante.

- **Contexto e Estado:**

Pequenas alterações em system messages, histórico ou ordem de mensagens.




## Conclusão parcial

### Natureza Probabilística

A execução de um LLM não é uma busca em banco de dados; é uma amostragem em espaço de probabilidade.

# O que significa dizer que ele “seguiu” uma instrução?

Desmistificando a execução lógica de regras em modelos estatísticos.



- O modelo **não executa regras rígidas** como um código Python condicional.
- Seguir instrução significa que o fine-tuning e RLHF **enviesaram a distribuição** de tokens para caminhos compatíveis com o pedido.
- É um comportamento estatístico aprendido e medido por probabilidade, nunca uma garantia absoluta.

Perspectiva de Agentes

## Confiabilidade Estatística

Erros de instrução são falhas de distribuição que exigem mitigação via prompts robustos e validação.

# Obrigado!

Espaço aberto para dúvidas e alinhamento da equipe de Benchmarks e Comportamento Agêntico.



Semana 2 — Alinhamento de Conteúdo Concluído