SEMANA 6 · BENCHMARKS E COMPORTAMENTO AGÊNTICO

Desenho experimental e reprodutibilidade

Como saber se uma diferença de resultado vem do método e não de uma comparação injusta ou do acaso?

Elisa · Ana Clara · Henrique

PERGUNTA ORIENTADORA DA SEMANA

Como saber se uma diferença vem do método e não de uma comparação injusta ou do acaso?

Hipótese, variáveis, configuração congelada, repetição, erros, rastreabilidade e reprodução: cada bloco responde uma parte desta pergunta.

O EXPERIMENTO QUE VAMOS ACOMPANHAR

Fine-tunar um modelo pequeno ajuda de verdade?

Tarefa
Sentimento em tweets em português (negativo, neutro, positivo). Teste fixo de 870 tweets, 290 por classe.

Modelo
Qwen2.5-0.5B-Instruct, um modelo de linguagem pequeno (SLM), rodando no Colab gratuito com GPU T4.

Métodos
Zero-shot e few-shot (só prompt) contra LoRA (fine-tuning leve).

Pergunta do caso: o LoRA melhora a classificação em relação a só usar prompt, e essa melhora é maior que o ruído entre seeds?

ANTES DE COMEÇAR

O mesmo método deu F1 de 0,58 e de 0,17

Mesmo modelo, mesmo teste, mesmas instruções. Só a seed mudou. Uma execução única teria nos enganado.

1

Desenhar o experimento

Elisa

Hipótese e unidade experimental · variáveis · configuração congelada · comparação justa

ELISA · HIPÓTESE

Uma hipótese que pode falhar

H1 (hipótese)

O modelo com LoRA tem F1-macro maior que o mesmo modelo com few-shot, no mesmo teste.

H0 (nula)

A diferença média de F1-macro entre LoRA e few-shot, entre seeds, é zero.

Unidade experimental

Uma execução completa: amostra de treino, treino e avaliação, com uma seed. O teste é fixo; as seeds são as repetições.

ELISA · UNIDADE EXPERIMENTAL

Uma execução produz uma observação

Seed
controla amostra, exemplos e inicialização

→

Treino
1.500 tweets sorteados

→

Método
Zero-shot, few-shot ou LoRA

→

Teste fixo
870 tweets, nunca mudam

→

Resultado
F1-macro e acurácia

Cinco seeds (0 a 4) dão cinco observações por método. O zero-shot é determinístico: roda uma vez.

ELISA · VARIÁVEIS

O que muda, o que mede, o que pode atrapalhar

Tipo	Variável	No experimento
Independente	Método	Zero-shot, few-shot, LoRA
Dependente	Métrica	F1-macro (principal) e acurácia
De confusão	Tudo que poderia explicar a diferença no lugar do método	Teste, amostra de treino, prompt, modelo, hiperparâmetros, seed

Controladas e declaradas

Controladas

Mesmo teste de 870 tweets, 290 por classe

Mesma amostra de treino por seed, para todos os métodos

Mesmo cabeçalho de prompt e mesma leitura do resultado

Mesmo modelo base e mesmo tamanho de treino (1.500)

Não controladas, declaradas

Não determinismo da GPU em meia precisão

Possível contaminação do pré-treino do modelo

Como lemos a resposta do modelo (1º token)

LoRA usa 1.500 rótulos; few-shot usa 6

ELISA · CONFIGURAÇÃO CONGELADA

Tudo que define o experimento fica num só lugar

```
model = Qwen2.5-0.5B-Instruct
n_train = 1500
k_shot = 6
lora = r16, alpha32
epochs = 2
lr = 2e-4
batch = 16
seeds = 0, 1, 2, 3, 4
```

Hashes registrados

config_hash

`bad39d0fd7f2249a`

test_hash

`7509d97cb78f7c97`

Cada execução grava os dois. Se algum mudar, o teste deixa de ser o mesmo.

ELISA · COMPARAÇÃO JUSTA

Três métodos, o que cada um recebe

Método	Rótulos usados	Prompt	Treino
Zero-shot	0	instrução + tweet	nenhum
Few-shot	6 (balanceados)	instrução + 6 exemplos + tweet	nenhum
LoRA	1.500	instrução + tweet	2 épocas, lr 2e-4

Checagem em código: mesmo teste, mesmo config e mesmo tamanho de treino em todas as execuções. Se algo diferir, o notebook para.

ELISA · LIMITE DA COMPARAÇÃO

1.500 rótulos contra 6 exemplos

Sem ajuste de taxa de aprendizado nem de prompt. O resultado vale para este orçamento, não para qualquer prompt bem feito.

2

Medir e entender os erros

Ana Clara

Seeds, média, dispersão, IC · análise de erros · resultados negativos

O básico: seed, média, dispersão e IC

Seed

Número que inicializa o gerador aleatório. Fixá-la torna os sorteios reproduzíveis

```
random.seed(0)
numpy.random.seed(0)
torch.manual_seed(0)
```

- Fixar não elimina a variabilidade, rode várias seed e relate todas
- Relatar só a melhor seed é seleção de resultados
- Defina a lista de seeds na config., antes de rodar.

Média, desvio e erro padrão

A média resume as repetições. O desvio padrão (s) mede quanto as repetições variam. O erro padrão (EP) mede a precisão da média e cai com mais repetições.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad \mathrm{EP} = \frac{s}{\sqrt{n}}$$

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Intervalo de confiança 95%

Faixa de valores plausíveis para a média verdadeira: repetindo o procedimento muitas vezes, cerca de 95% dos intervalos conteriam o valor verdadeiro

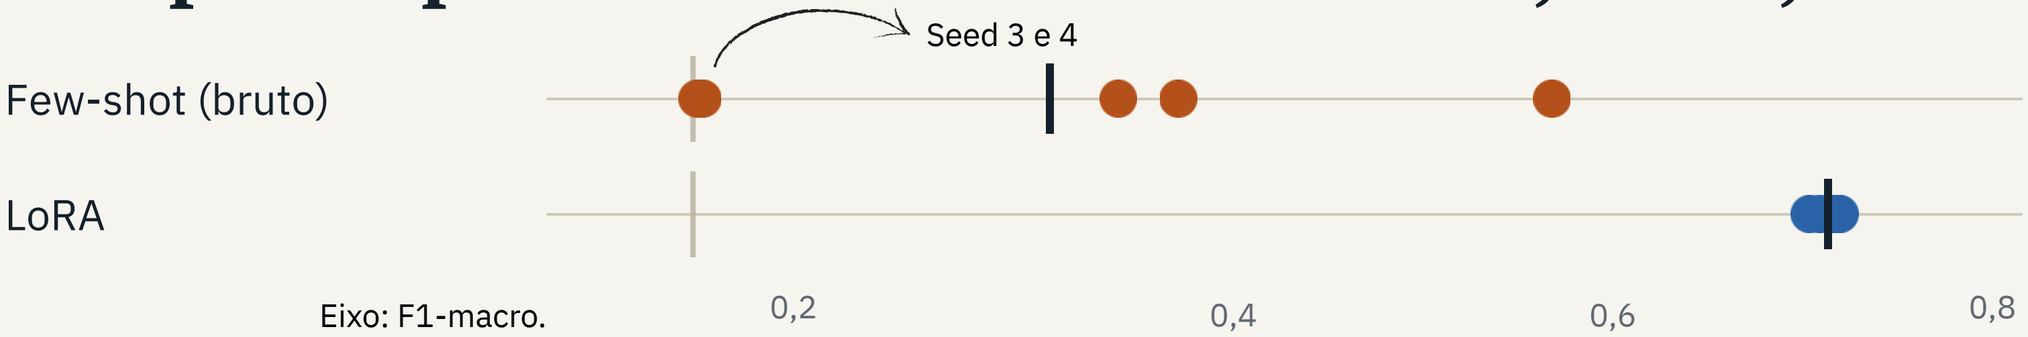
$$\mathrm{IC}_{95\%} = \bar{x} \pm t_{n-1} \cdot \mathrm{EP}$$

t de student: n = 5
t4 → t = 2,776
tabela distribuição t de student

No LoRA:
0,707 ± 0,008 → de 0,700 a 0,715

ANA CLARA · REPETIÇÃO E DISPERSÃO

Um ponto por seed: o few-shot vai de 0,17 a 0,58



Cada ponto é uma seed, que muda a amostra de treino, os exemplos do prompt, a inicialização e a ordem dos lotes.
O traço preto é a média do método.
A linha cinza vertical marca o zero-shot (0,169).

Média e IC por método (F1-macro)

Método	Média	Desvio	IC 95%
LoRA	0,707	0,006	0,700 a 0,715
Few-shot (bruto)	0,339	0,171	0,127 a 0,551
Zero-shot	0,169	uma execução	determinístico

O intervalo do few-shot é quase 30 vezes mais largo que o do LoRA. É um sinal de que há algo errado com ele.

ANA CLARA · DIFERENÇA PAREADA

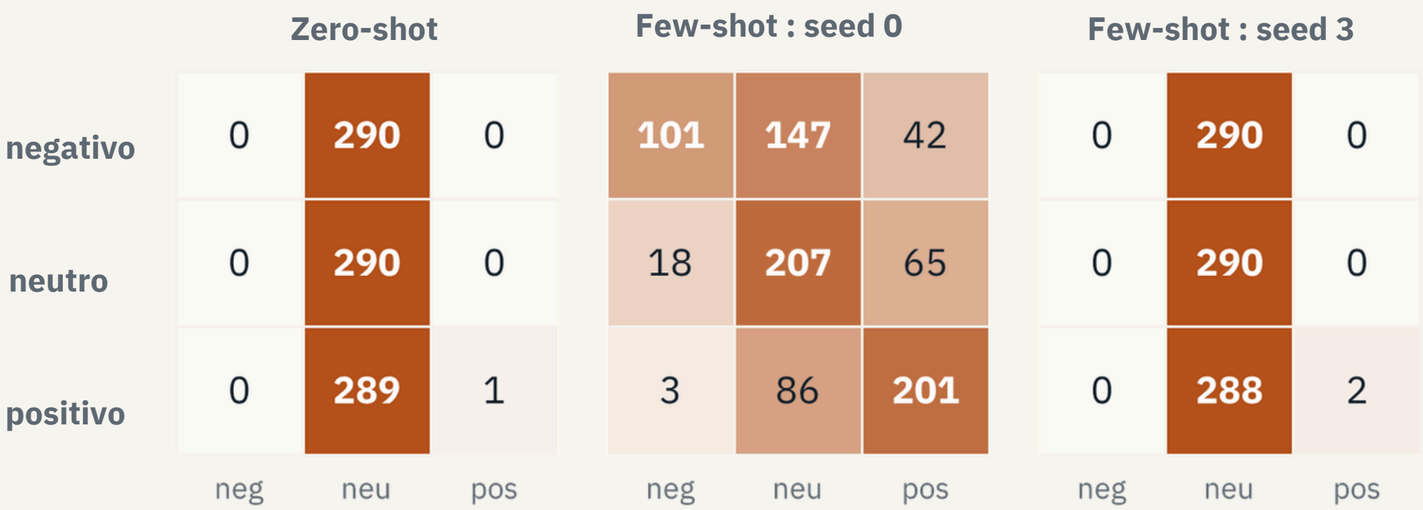
A comparação certa é seed a seed

Seed	LoRA	Few-shot (bruto)	Diferença
0	0,699	0,577	0,122
1	0,71	0,4	0,31
2	0,704	0,371	0,332
3	0,713	0,172	0,542
4	0,712	0,174	0,538

Comparação	Diferença média	IC 95%	Seeds a favor
LoRA – few-shot (bruto)	+0,369	0,150 a 0,588	5 de 5

Pareamos por seed porque, dentro da mesma seed, os métodos usam a mesma amostra de treino. Se o IC da diferença não cruza zero, o efeito passa do ruído; se cruza, o resultado é inconclusivo.

Zero-shot e few-shot preveem quase só neutro



Previsões “neutro”, de 870 tweets

Zero-shot: 869

Few-shot seed 3: 868

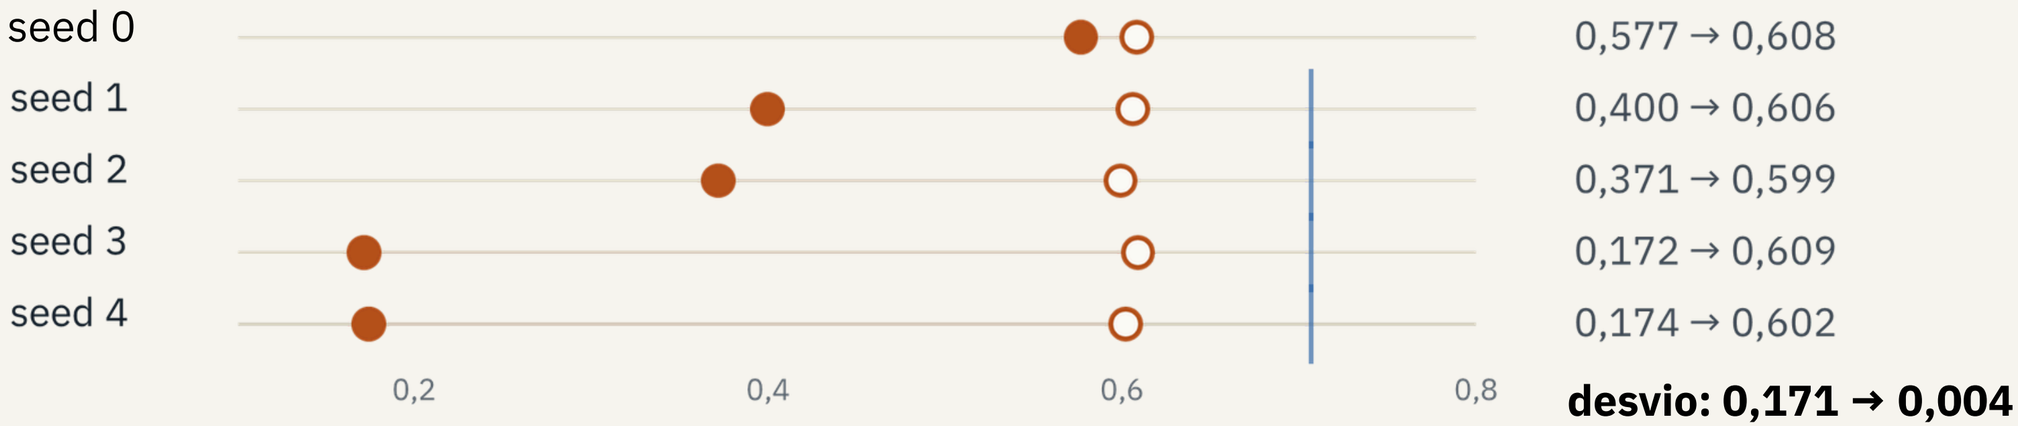
Few-shot seed 4: 866

Com 290 tweets por classe, prever sempre neutro rende cerca de 33% de acerto.

Linhas: classe real. Colunas: classe prevista. Quanto mais escuro, mais tweets.

A causa provável: viés do primeiro token

Lemos só o primeiro token de cada rótulo depois de “Sentimento:”, o modelo tem uma preferência de fábrica por ‘neutro’
Calibração: medir essa preferência na validação e descontá-la antes de escolher a resposta.



Ponto cheio: F1 antes da correção. Ponto vazado: F1 depois da correção.
Linha azul: média do LoRA (0,707).

Transparência: essa análise não estava planejada. Foi feita depois de ver o colapso, e por isso entra como diagnóstico, não como hipótese confirmada.

A causa provável: viés do primeiro token

1. Referência fixa: na validação (324 tweets, sem usar rótulos), medimos a probabilidade típica que o modelo dá para cada classe. É calculada uma vez por seed e vale para todos os tweets do teste. Mostra o costume do modelo: em média ele dá 95% para neutro, qualquer que seja o tweet.
2. O tweet: o modelo dá uma probabilidade para cada classe naquele tweet específico.
3. Comparação: dividimos a probabilidade do tweet pela típica e escolhemos a classe que ficou mais acima do normal.

	negativo	neutro	positivo
Típico na validação (costume do modelo)	0,03	0,95	0,02
Um tweet do teste (de fato negativo)	0,10	**0,85** ← bruto escolhe	0,05
Tweet ÷ típico	**3,3×** ← calibrado escolhe	0,9×	2,5×

De onde vêm os pontos vazados: refazemos essa escolha para os 870 tweets do teste e calculamos o F1 de novo. Cada ponto vazado é esse F1 recalculado, um por seed (0,608, 0,606, 0,599, 0,609 e 0,602). O ponto cheio da mesma linha é o F1 antes da correção.

ANA CLARA · A CONCLUSÃO MUDA

LoRA melhora ainda, mas em +0,10, e não em +0,37

LoRA – few-shot calibrado: +0,103 (IC 95% de 0,094 a 0,112), nas 5 seeds.

ANA CLARA · RESULTADOS NEGATIVOS

Três resultados negativos que entram no relatório

LoRA com taxa 10 vezes maior

Com lr 2e-3, o treino divergiu: F1 de 0,167 e perda final de 1,145, acima do chute (cerca de 1,10). Previu “positivo” em 870 de 870 tweets.

Few-shot bruto

O colapso ao neutro não era incapacidade do modelo, era viés da leitura da resposta.

Ganho menor que o esperado

Com a leitura calibrada, a vantagem do LoRA caiu de +0,37 para +0,10.

O que este experimento não permite concluir

Cinco seeds: o IC é largo e aproximado.

Um modelo, um dataset, um idioma.

Teste fixo: o IC não inclui a variação da escolha do teste.

Possível contaminação do pré-treino do Qwen.

Calibração feita depois de ver o resultado.

3

Rastrear, reproduzir, replicar

Rastreabilidade de dados, modelos, prompts, código e execuções · executar, reproduzir e replicar

RASTREABILIDADE

F1 = 0,707

Se eu te mandar só esse número, você consegue conferir de onde ele veio?

O QUE RASTREAR

Cinco coisas, cada uma com seu registro

O que	Onde fica no experimento
Dados	test_hash (teste) e train_hash (amostra de cada seed)
Modelo	Nome e configuração do LoRA no CONFIG
Prompts	prompt_header salvo em cada execução
Código	Versões das bibliotecas, Python e GPU (env)
Execuções	Um arquivo run_*.json por seed, com data e hora

Rastreabilidade: conseguir responder, para qualquer número, de onde ele veio e em que condições foi gerado.

· O MANIFEST

Cada execução deixa um arquivo como este

```
seed: 0
n_train: 1500
train_hash: 8c897cd3c4ef7009
test_hash: 7509d97cb78f7c97
config_hash: bad39d0fd7f2249a
lora.f1_macro: 0.6986
final_train_loss: 0.662
gpu: Tesla T4
torch: 2.11.0 · peft: 0.21.2
timestamp: 2026-10-20 20:22
```

Por quê

Cada número da tabela de resultados aponta para um arquivo. Quem desconfiar de um valor consegue abrir a execução que o gerou.

O REGISTRO

Uma tabela que liga cada resultado ao seu arquivo

Arquivo	Método	Seed	F1-macro	Hora (UTC)
run_zeroshot.json	zero-shot	—	0,169	20:19
run_main_seed0.json	LoRA	0	0,699	20:22
run_main_seed3.json	LoRA	3	0,713	20:31
run_main_seed4.json	LoRA	4	0,712	20:32
run_ablation_lr0.002_seed0.json	LoRA, lr 2e-3	0	0,167	20:34

O registro é gerado a partir dos manifests e cobre 13 execuções, incluindo a reprodução, a replicação e a checagem das seeds 1 e 2. Aqui, um recorte.

UM CASO REAL

A sessão caiu no meio da coleta e o código mudou

Seeds 0 a 2
código antigo

→

Pausa de 6 min
falta de RAM, ajuste no carregamento do modelo

→

Seeds 3 e 4
código novo

Mesmo config_hash dos dois lados

O hash não denunciou a mudança (sequência inferida dos horários dos arquivos). O que resolveu foi reproduzir: refazer as seeds 0, 1 e 2 com o código novo deu predições idênticas às originais.

Também ficaram fora do hash: exemplos do few-shot · revisão do Qwen e do dataset · rótulos do teste

EXECUTAR, REPRODUZIR, REPLICAR

Três verbos, três perguntas diferentes

Termo	O que muda	A pergunta que responde
Executar	Nada: roda uma vez	Funciona?
Reproduzir	Nada: mesmo código, dados, config e seed	Dá o mesmo resultado?
Replicar	Algo legítimo: novas amostras, outro teste ou outro conjunto	A conclusão se mantém?

REPRODUZIR

Seed 0 refeita: resultado idêntico

Método	Original	Reproduzido	Diferença
Few-shot (bruto)	0,5766	0,5766	0,0000
LoRA	0,6986	0,6986	0,0000

As predições dos 870 tweets também saíram idênticas, e o mesmo vale para as seeds 1 e 2 refeitas com o código novo. A tolerância de 0,02 era precaução.

O QUE QUEBRA A REPRODUÇÃO

Mesma configuração, resultado diferente: por quê?

Causa	O que muda entre equipes e máquinas	Efeito
Aritmética de ponto flutuante	Outra GPU soma os números em ordem diferente	Diferenças minúsculas nos pesos e nos logits
Versões de software	PyTorch, CUDA, transformers, peft	Kernels e valores padrão diferentes
Seed não cobre tudo	Operações paralelas da GPU não são determinísticas	A mesma seed não garante o mesmo cálculo

Diferença pequena de número é esperada. Mudar a conclusão é o que preocupa.

REPLICAR

Seeds novas: a direção do ganho se mantém

Seed	Few-shot (bruto)	LoRA
100	0,368	0,706
101	0,185	0,718
102	0,234	0,716

LoRA – few-shot

+0,369 original · +0,451 replicação

Few-shot (bruto)

0,185 a 0,368, instável de novo

É uma replicação interna: mesmo teste e mesmo pipeline, só amostras de treino novas. Uma replicação mais forte mudaria o dataset ou o teste.

Obrigado!